



BURSA ULUDAĞ ÜNİVERSİTESİ

2025 – 2026 Eğitim Öğretim Yılı Bahar Dönemi

Python Programlamaya Giriş

Derin Öğrenme Tabanlı Videolarda Deepfake Yüz Manipülasyonu Tespiti

Proje Raporu

Bursa Uludağ Üniversitesi Bilgisayar Mühendisliği

Mertcan TAŞKIRAN, Füsün GÜN, Büşra DERELİ

032290113, 032490014, 032490047

032290113@ogr.uludag.edu.tr

032490014@ogr.uludag.edu.tr

032490047@ogr.uludag.edu.tr

BİLGİSAYAR MÜHENDİSLİĞİ PROJE RAPORU

1. Proje Adı: Videolarda Deepfake Manipülasyonlarının Derin Öğrenme ile Tespiti

2. Proje Konusu: Yapay zeka algoritmaları (özellikle GAN ve VAE mimarileri) kullanılarak manipüle edilen yüz videolarının, evrişimli sinir ağları (CNN) ve biyometrik tutarsızlık analizi ile gerçek zamanlı tespit edilmesi.

3. GitHub Linki: <https://github.com/Mertcan-T/deepfake-detection-system>


4. Yöntem (Proje Adımları)

Projemiz, literatürdeki "Deepfake Detection Pipeline" standartlarına uygun olarak beş ana adımda çalışacaktır:

- Veri Girişi (Ingestion):** Ham video dosyasının sisteme yüklenmesi ve OpenCV kullanılarak karelere (frames) bölünmesi.
- Yüz Tespiti ve Hizalama (Preprocessing):** Her karedeki yüz bölgesinin facenet-pytorch (MTCNN) ile saptanarak 160x160 boyutuna normalize edilmesi.
- Özellik Çıkarımı (Feature Extraction):** PyTorch tabanlı InceptionResnetV1 mimarisi ile yüzdeki piksellerin ve doku artefaktlarının sayısallaştırılması.
- Sınıflandırma (Classification):** Eğitilmiş modelin, çıkarılan özellikleri analiz ederek videonun "Gerçek" veya "Sahte" olduğuna karar vermesi.
- Arayüz Sunumu (Deployment):** Sonuçların Streamlit platformu üzerinden kullanıcıya görsel bir rapor şeklinde sunulması.

5. Algoritma Akış Şeması (Flowchart)

- Girdi:** Kullanıcı tarafından yüklenen .mp4 veya .avi formatındaki video dosyası.
- İşlem:** Videonun karelere ayrılması -> MTCNN ile yüz tespiti -> Tensör dönüşümü ve Normalizasyon.
- Hesaplama:** InceptionResnetV1 katmanları üzerinden ileri besleme (forward pass) yapılarak Softmax fonksiyonu ile olasılık skorunun hesaplanması.
- Çıktı:** İkili sınıflandırma (Real/Fake) sonucu ve yüzde (%) cinsinden güven skoru.



6. Uygulama Tasarımı

- **Kullanıcı Ne Girecek?** Web arayüzündeki "Dosya Yükle" butonu aracılığıyla bir video dosyası yükleyecek.
- **Program Ne Hesaplayacak?** Videonun her karesindeki yapaylık oranını ve biyometrik tutarlılığı hesaplayarak genel bir "Deepfake Skoru" üretecek.
- **Sonuç Nasıl Gösterilecek?** Streamlit ekranında videonun yanında "DİKKAT: SAHTE İÇERİK" veya "GÜVENLİ: GERÇEK VİDEO" uyarısı, tespit edilen yüzün kare içindeki görüntüsü ve olasılık grafiği ile gösterilecek.

7. Başarı Ölçütleri

- **Doğruluk (Accuracy):** Modelin FaceForensics++ veri seti üzerindeki test başarısının hedeflenen seviyede olması.
- **Düşük Yanlış Pozitif:** Gerçek videoların yanlışlıkla "sahte" olarak işaretlenme oranının (FPR) minimize edilmesi.
- **Performans:** Bir videonun analiz süresinin, videonun süresinden daha kısa olması (Hızlı tespit).

8. Teknik Kısım: Çalışan İlk Prototip (Modular Code)

Projenin ana akışını kuran, modüler yapıdaki ilk çalışan kod bloğumuz şöyledir:

```
import cv2
import os
import torch
from facenet_pytorch import MTCNN

def yuz_tespiti_ve_kayit_mtcnn(giris_videosu, cikti_videosu):
    """
    Belirtilen videoyu okur, MTCNN (Derin Öğrenme) ile yuzleri bulur
    ve islenmis halini yeni bir video olarak kaydeder.
    """
    # 1. Dosya Kontrolü
    if not os.path.exists(giris_videosu):
        print("Hata: Video dosyasi bulunamadi. Lutfen dosya yolunu kontrol
edin.")
        return

    # 2. MTCNN Yuz Tanima Modelini Yukle (PyTorch tabanlı)
    device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
    # keep_all=True ile karedeki tum yuzleri bulmasini sagliyoruz
    yuz_detektoru = MTCNN(keep_all=True, device=device)
    print(f"MTCNN Modeli {device} uzerinde basariyla yuklendi.")

    # 3. Videoyu Ac ve Teknik Ozelliklerini Al
    kamera = cv2.VideoCapture(giris_videosu)
    genislik = int(kamera.get(cv2.CAP_PROP_FRAME_WIDTH))
    yukseklik = int(kamera.get(cv2.CAP_PROP_FRAME_HEIGHT))
    fps = int(kamera.get(cv2.CAP_PROP_FPS))
    toplam_kare = int(kamera.get(cv2.CAP_PROP_FRAME_COUNT))

    # 4. Video Kaydediciyi Ayarla
    fourcc = cv2.VideoWriter_fourcc(*'mp4v')
```

```
video_kaydedici = cv2.VideoWriter(cikti_videosu, fourcc, fps, (genislik,
yukseklilik))

print(f"Islem basladi... Toplam islenecek kare: {toplam_kare}")
islenen_kare_sayisi = 0

# 5. Videoyu Kare Kare Isleyen Ana Dongu
while True:
    basarili_mi, kare = kamera.read()
    if not basarili_mi:
        break

    islenen_kare_sayisi += 1

    # MTCNN RGB formatinda calistigi icin BGR'den RGB'ye ceviriyoruz
    kare_rgb = cv2.cvtColor(kare, cv2.COLOR_BGR2RGB)

    # Yuzleri tespit et (Kutu koordinatlarini dondurur)
    boxes, _ = yuz_detektoru.detect(kare_rgb)

    # Eger yuz bulunduyrsa yesil dikdortgen ciz
    if boxes is not None:
        for box in boxes:
            # MTCNN float dondurur, cv2.rectangle integer bekler
            x1, y1, x2, y2 = [int(b) for b in box]
            cv2.rectangle(kare, (x1, y1), (x2, y2), (0, 255, 0), 2)

        bulunan_yuz_sayisi = len(boxes)
    else:
        bulunan_yuz_sayisi = 0

    # Bilgi metni ekle
    bilgi_metni = f"Kare: {islenen_kare_sayisi}/{toplam_kare} | Yuz:
{bulunan_yuz_sayisi}"
    cv2.putText(kare, bilgi_metni, (20, 40), cv2.FONT_HERSHEY_SIMPLEX,
0.7, (0, 0, 255), 2)

    # 6. Ekranda goster ve dosyaya kaydet
    cv2.imshow("Deepfake Onisleme - MTCNN", kare)
    video_kaydedici.write(kare)

    if cv2.waitKey(1) & 0xFF == ord('q'):
        print("Islem kullanici tarafindan durduruldu.")
        break

# 7. Hafizayi temizle
```


```
kamera.release()
video_kaydedici.release()
cv2.destroyAllWindows()
print("\nVideo isleme ve kaydetme islemi basariyla tamamlandi.")
print(f"Cikti dosyasi: {cikti_videosu}")

if __name__ == "__main__":
    # Orijinal videonuzun yolu (Basindaki 'r' harfi Windows dizin yapisi icin kritiktir)
    video_yolu = r"C:\Users\M.T\Desktop\calismalarim\DeepFake Python\deepfake-detection-system\src\videolar\Deepfake Example Presented by Senator Richard Blumenthal.mp4"

    # Islenmis videonun kaydedilecegi yol
    kayit_yolu = r"C:\Users\M.T\Desktop\calismalarim\DeepFake Python\deepfake-detection-system\src\videolar\Deepfake_Example_islenmis_mtcnn.mp4"

    # Fonksiyonu cagir
    yuz_tespiti_ve_kayit_mtcnn(video_yolu, kayit_yolu)
```

8.1 Örnek Senaryo Ara Çıktısı



9. Literatür Taraması:

1. Giriş

Yapay zekâ teknolojilerindeki hızlı gelişim, görüntü işleme ve bilgisayarlı görü alanlarında önemli ilerlemeler sağlamıştır. Özellikle derin öğrenme tabanlı üretici modellerin gelişmesiyle birlikte gerçeğe oldukça yakın sahte görüntü, video ve ses içerikleri üretilebilmektedir. Bu içerikler literatürde “Deepfake” olarak adlandırılmaktadır. Deepfake kavramı, “deep learning” ve “fake” kelimelerinin birleşiminden oluşmakta olup yapay zekâ kullanılarak üretilen sentetik medya içeriklerini ifade etmektedir.

Deepfake teknolojisi ilk dönemlerde eğlence ve medya sektöründe dikkat çekmiş olsa da zaman içerisinde bilgi güvenliği, biyometrik doğrulama, medya güvenilirliği ve siber güvenlik açısından ciddi tehditler oluşturmaya başlamıştır. Özellikle kamuoyunda tanınan kişilerin görüntülerinin manipüle edilmesi, yanlış bilgi yayılımı, kimlik sahteciliği ve sosyal mühendislik saldırıları gibi problemler bu teknolojinin olumsuz yönlerini ortaya koymuştur. Bunun sonucunda Deepfake içeriklerin tespit edilmesine yönelik çalışmalar hız kazanmış ve medya adli bilişimi (Media Forensics) alanı önemli bir araştırma konusu haline gelmiştir (Verdoliva, 2020).

Literatürde Deepfake tespitine yönelik çalışmalar; biyometrik analizler, fizyolojik davranış incelemeleri, evrişimli sinir ağları (CNN), zamansal analiz yöntemleri ve transformer tabanlı modeller gibi farklı yaklaşımlar altında incelenmektedir. Bu çalışmada Deepfake teknolojisinin gelişimi, temel tespit yöntemleri, veri setleri ve güncel araştırma yaklaşımları detaylı şekilde ele alınmıştır.

2. Deepfake Teknolojisinin Tarihsel Gelişimi

Deepfake teknolojisinin temelini, Ian Goodfellow ve çalışma arkadaşları tarafından geliştirilen Üretken Çekişmeli Ağlar (GAN) oluşturmaktadır. GAN mimarisi ilk kez 2014 yılında önerilmiş ve iki sinir ağının birbirine karşı çalışması prensibine dayandırılmıştır (Goodfellow et al., 2014). Bu yapıda üretici ağ (generator) sahte görüntüler üretirken, ayırt edici ağ (discriminator) görüntülerin gerçek mi yoksa sahte mi olduğunu belirlemeye çalışmaktadır. Eğitim süreci ilerledikçe üretici ağ giderek daha gerçekçi içerikler oluşturabilmektedir.

İlk dönemlerde GAN tabanlı çalışmalar daha çok düşük çözünürlüklü görüntü üretimi üzerine yoğunlaşırken, ilerleyen süreçte yüksek çözünürlüklü yüz manipülasyonları mümkün hale gelmiştir. Özellikle yüz değiştirme (Face Swap), dudak senkronizasyonu (Lip Sync) ve ses klonlama gibi tekniklerin gelişmesi Deepfake teknolojisinin yaygınlaşmasına neden olmuştur.

Deepfake teknolojilerinin gelişmesiyle birlikte sosyal medya platformlarında sahte videoların yayılması önemli bir problem haline gelmiştir. Özellikle seçim süreçleri, kamu güvenliği ve medya manipülasyonu açısından Deepfake içeriklerin ciddi tehdit oluşturduğu görülmüştür. Bu nedenle araştırmacılar Deepfake içeriklerin otomatik olarak tespit edilmesine yönelik yöntemler geliştirmeye başlamıştır (Mirsky & Lee, 2021).

3. Biyometrik ve Fizyolojik Tabanlı Deepfake Tespit Yöntemleri

Deepfake tespitine yönelik ilk çalışmalar, insan fizyolojisine ait doğal davranışların yapay zekâ modelleri tarafından tam anlamıyla taklit edilememesi üzerine yoğunlaşmıştır. Özellikle göz kırpma hareketleri, yüz kaslarının doğal tepkileri, baş hareketleri ve mikro mimikler gibi istemsiz davranışlar önemli analiz kriterleri olarak değerlendirilmiştir.

3.1 Göz Kırpma Analizi

Li ve arkadaşları (2018), geliştirdikleri “In Ictu Oculi” çalışmasında Deepfake videolarındaki bireylerin doğal göz kırpma davranışlarını yeterince taklit edemediğini göstermiştir. Araştırmada gözün açık ve kapalı kalma süreleri zamansal olarak incelenmiş ve manipüle edilmiş videolarda insan davranışına aykırı örüntüler tespit edilmiştir. Çalışmada erken dönem Deepfake içeriklerinin tespitinde yüksek doğruluk oranları elde edilmiştir. Bu durum, projede kullanılacak zamansal analiz yöntemlerinin önemini desteklemektedir (Li et al., 2018).

3.2 Görsel Artifact Analizleri

Matern ve arkadaşları (2019), manipüle edilmiş yüzlerde oluşan görsel kusurları inceleyerek özellikle göz yansımaları, yüz dokuları ve diş yapılarındaki geometrik tutarsızlıklara odaklanmıştır. Araştırmada, diş dizilimlerinde oluşan keskin kenar hatalarının (edge artifacts) Deepfake içeriklerin ayırt edilmesinde önemli bir belirteç olduğu vurgulanmıştır. Çalışma sonucunda yalnızca piksel tabanlı değil, aynı zamanda geometrik ve fotometrik analizlerin de Deepfake tespitinde kritik rol oynadığı ortaya koyulmuştur (Matern et al., 2019).

3.3 Yumuşak Biyometrik Özellikler

Agarwal ve arkadaşları (2019), özellikle kamuoyunda tanınan kişilere yönelik Deepfake saldırılarını tespit etmek amacıyla davranışsal biyometri tabanlı bir yöntem önermiştir. Çalışmada baş hareketleri, mimikler, dudak koordinasyonu ve konuşma sırasındaki yüz hareketleri analiz edilmiştir. Bu yaklaşım, yalnızca görüntü kalitesine değil bireyin davranışsal bütünlüğüne odaklanması bakımından literatürde özgün bir yere sahiptir.

4. CNN Tabanlı Deepfake Tespit Yaklaşımları

Derin öğrenmenin gelişmesiyle birlikte Deepfake tespitinde Evrişimli Sinir Ağları (CNN) yaygın olarak kullanılmaya başlanmıştır. CNN tabanlı modeller, görüntü içerisindeki karmaşık örüntüleri öğrenebilme yetenekleri sayesinde yüksek doğruluk oranları sağlayabilmektedir.

4.1 MesoNet

Afchar ve arkadaşları (2018), Deepfake videolarındaki mesoskopik özellikleri analiz etmek amacıyla MesoNet mimarisini geliştirmiştir. Meso-4 ve MesoInception-4 olmak üzere iki farklı yapı önerilmiş ve bu modellerin düşük parametre sayısı ile yüksek performans sağlayabildiği gösterilmiştir. Özellikle düşük çözünürlüklü ve sıkıştırılmış videolarda başarılı sonuçlar elde edilmesi, bu yaklaşımın gerçek dünya senaryoları açısından önemini artırmaktadır.

4.2 FaceNet ve Embedding Yaklaşımı

Schroff ve arkadaşları (2015) tarafından geliştirilen FaceNet modeli, yüz görüntülerini vektörel temsillere dönüştürmek amacıyla geliştirilmiştir. Modelde kullanılan Triplet Loss yaklaşımı sayesinde aynı kişiye ait yüz görüntüleri birbirine yakın, farklı kişilere ait görüntüler ise birbirinden uzak vektörler olarak temsil edilmektedir. Bu yöntem, Deepfake tespitinde sahte yüzlerin gerçek yüzlerden ne ölçüde saptığını analiz etmek için kullanılmaktadır.

4.3 Xception Mimarisi

François Chollet tarafından geliştirilen Xception mimarisi, derinlik bazlı ayrılabilir evrişimler (depthwise separable convolutions) kullanarak daha düşük hesaplama maliyetiyle yüksek doğruluk sağlamaktadır (Chollet, 2017). Xception tabanlı modeller, Deepfake tespitinde özellikle yüz üzerindeki ince manipülasyonları ve doku bozulmalarını belirlemede başarılı sonuçlar vermektedir.

Günümüzde Xception mimarisi çoğunlukla PyTorch altyapısıyla kullanılmaktadır. PyTorch'un dinamik hesaplama grafikleri (dynamic computation graphs) sayesinde modellerin eğitimi, hata ayıklama süreçleri ve transfer öğrenme uygulamaları daha esnek hale gelmektedir. Bu durum araştırma ve geliştirme süreçlerinde önemli avantaj sağlamaktadır.

4.4 MTCNN ile Yüz Hizalama

Kaipeng Zhang ve arkadaşları (2016) tarafından geliştirilen Çok Görevli Evrişimsel Sinir Ağları (MTCNN), yüz tespiti ve hizalama işlemlerini aynı mimari içerisinde gerçekleştirmektedir. Bu yöntem yalnızca yüzün tespit edilmesini değil; gözler, burun ve ağız köşeleri gibi beş temel referans noktasının belirlenmesini de sağlamaktadır.

Projede kullanılacak olan bu yapı sayesinde yüz görüntüleri standart bir hizalamaya tabi tutulacak ve modelin hata payı azaltılacaktır. Ayrıca MTCNN mimarisinin PyTorch ortamında uygulanabilmesi, dinamik grafik yapısı sayesinde farklı veri setleri üzerinde daha hızlı optimizasyon yapılmasına olanak tanımaktadır (Zhang et al., 2016).

5. Zamansal Analiz ve Video Tabanlı Yaklaşımlar

Deepfake videolarında yalnızca tek karelerin değil, videonun zamansal akışının da incelenmesi gerekmektedir. Çünkü manipülasyonlar çoğu zaman kareler arasında tutarsızlıklara neden olmaktadır.

5.1 RNN ve LSTM Yaklaşımları

Guera ve Delp (2018), CNN çıktılarının Rekürrent Sinir Ağlarına (RNN) aktarılmasıyla kareler arasındaki zamansal tutarsızlıkların analiz edilebileceğini göstermiştir. Bu yöntem sayesinde videolardaki ani piksel değişimleri ve zamansal bozulmalar daha başarılı şekilde tespit edilebilmiştir.

Özellikle kareler arasındaki geçişlerin doğal olmaması Deepfake videolarının belirlenmesinde önemli rol oynamaktadır. Bu yaklaşım, video tabanlı Deepfake tespit sistemlerinde zamansal analizlerin neden gerekli olduğunu ortaya koymaktadır.

5.2 Capsule Networks

Nguyen ve arkadaşları (2019) tarafından geliştirilen Capsule-Forensics yaklaşımı, yüz organlarının birbirleriyle olan konumsal ilişkilerini incelemektedir. Geleneksel CNN yapılarından farklı olarak Capsule Networks, uzamsal ilişkileri daha başarılı şekilde koruyabilmektedir.

Bu yaklaşım sayesinde göz, burun ve ağız gibi yüz organlarının orantısız hareketleri tespit edilebilmekte ve manipülasyonlar daha doğru şekilde belirlenebilmektedir.

6. Veri Setleri ve Benchmark Çalışmaları

Deepfake tespit sistemlerinin başarısı büyük ölçüde kullanılan veri setlerinin çeşitliliğine ve gerçek dünya koşullarını yansıtabilmesine bağlıdır.

6.1 FaceForensics++

Rosler ve arkadaşları (2019) tarafından geliştirilen FaceForensics++ veri seti, Deepfake araştırmalarında en yaygın kullanılan benchmark veri setlerinden biridir. Veri seti içerisinde Deepfakes, FaceSwap, Face2Face ve NeuralTextures gibi farklı manipülasyon teknikleri bulunmaktadır.

Araştırmacılar, veri setindeki yüksek kaliteli (HQ) ve düşük kaliteli (LQ) videolar üzerinde gerçekleştirdikleri deneylerde, sıkıştırma oranlarının Deepfake tespit performansını doğrudan etkilediğini göstermiştir. Özellikle düşük kaliteli videolarda doğruluk oranlarının düşmesi, gerçek dünya koşullarında çalışan sistemlerin geliştirilmesi gerektiğini ortaya koymaktadır. Bu nedenle FaceForensics++ veri seti projede temel veri kaynaklarından biri olarak değerlendirilmektedir.

6.2 DFDC Veri Seti

Dolhansky ve arkadaşları (2020) tarafından geliştirilen Deepfake Detection Challenge (DFDC) veri seti, gerçek dünya koşullarını içeren büyük ölçekli bir benchmark ortamı sunmaktadır. Düşük çözünürlük, farklı kamera açıları, ışık değişimleri ve gürültülü ortamlar gibi faktörler sayesinde modellerin genelleme kabiliyeti değerlendirilebilmektedir.

6.3 Güvenlik Açıkları ve Yüz Tanıma Sistemleri

Korshunov ve Marcel (2018), Deepfake videolarının yüz tanıma sistemlerini yanıltma potansiyelini incelemiştir. Araştırma sonucunda mevcut biyometrik doğrulama sistemlerinin önemli ölçüde kandırılabilirdiği görülmüş ve bu durum Deepfake teknolojilerinin güvenlik açısından oluşturduğu riski ortaya koymuştur.

7. Güncel Yaklaşımlar ve Gelecek Perspektifi

Son yıllarda transformer tabanlı modellerin gelişmesiyle birlikte Deepfake tespit sistemlerinde yeni yaklaşımlar ortaya çıkmıştır. Özellikle Vision Transformer (ViT) tabanlı modeller, görüntü içerisindeki uzun menzilli ilişkileri analiz ederek daha başarılı sonuçlar elde etmektedir.

Bunun yanında Explainable AI (Açıklanabilir Yapay Zekâ) yöntemleri de önem kazanmaktadır. Geleneksel modeller yalnızca içeriğin sahte olduğunu belirtirken, açıklanabilir sistemler hangi bölgelerin neden şüpheli olduğunu da gösterebilmektedir.

Mirsky ve Lee (2021) tarafından hazırlanan kapsamlı derleme çalışması, Deepfake üretim ve tespit yöntemlerinin sürekli gelişen bir rekabet içerisinde olduğunu belirtmektedir. Benzer şekilde Verdoliva (2020), Deepfake probleminin yalnızca teknik değil; etik, hukuki ve toplumsal boyutları olan bir konu olduğunu vurgulamıştır.

Gelecekte geliştirilecek sistemlerin çok modlu analiz yöntemleri, gerçek zamanlı tespit mekanizmaları ve açıklanabilir yapay zekâ tabanlı modeller üzerine yoğunlaşacağı öngörülmektedir.

KAYNAKÇA

Afchar, D., Nozick, V., Yamagishi, J., & Echizen, I. (2018). *MesoNet: A compact facial video forgery detection network*. IEEE International Workshop on Information Forensics and Security (WIFS), 1–7.

Agarwal, S., Farid, H., Fried, O., & Agrawala, M. (2019). *Protecting world leaders from deepfakes*. IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 38–45.

Chollet, F. (2017). *Xception: Deep learning with depthwise separable convolutions*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 1251–1258.

Cozzolino, D., Poggi, G., & Verdoliva, L. (2017). *Recasting residual-based local descriptors as convolutional neural networks*. ACM Workshop on Information Hiding and Multimedia Security, 159–164.

Dolhansky, B., Howes, R., Pflaum, B., Baram, N., & Ferrer, C. C. (2020). *The Deepfake Detection Challenge (DFDC) preview dataset*. arXiv preprint arXiv:1910.08854.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). *Generative adversarial nets*. Advances in Neural Information Processing Systems, 27, 2672–2680.

Guera, D., & Delp, E. J. (2018). *Deepfake video detection using recurrent neural networks*. IEEE International Conference on Advanced Video and Signal Based Surveillance, 1–6.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778.

Hsu, C. C., Zhuang, Y. X., & Lee, C. Y. (2020). *Deep fake image detection based on pairwise learning*. Applied Sciences, 10(1), 370.

Korshunov, P., & Marcel, S. (2018). *Deepfakes: A new threat to face recognition? Assessment and detection*. arXiv preprint arXiv:1812.08685.

Li, Y., Chang, M. C., & Lyu, S. (2018). *In Ictu Oculi: Exposing AI generated fake videos by detecting eye blinking*. IEEE International Workshop on Information Forensics and Security (WIFS), 1–7.

Li, Y., & Lyu, S. (2019). *Exposing deepfake videos by detecting face warping artifacts*. IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, 46–52.

Matern, F., Riess, C., & Stamminger, M. (2019). *Exploiting visual artifacts to expose deepfakes and face manipulations*. IEEE Winter Applications of Computer Vision Workshops, 83–92.

- Mirsky, Y., & Lee, W. (2021). *The creation and detection of deepfakes: A survey*. ACM Computing Surveys, 54(1), 1–38.
- Nguyen, H. H., Yamagishi, J., & Echizen, I. (2019). *Capsule-forensics: Using capsule networks to detect forged images and videos*. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2307–2311.
- Rossler, A., Cozzolino, D., Verdoliva, L., Riess, C., Thies, J., & Nießner, M. (2019). *FaceForensics++: Learning to detect manipulated facial images*. IEEE International Conference on Computer Vision (ICCV), 1–11.
- Schroff, F., Kalenichenko, D., & Philbin, J. (2015). *FaceNet: A unified embedding for face recognition and clustering*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 815–823.
- Tolosana, R., Vera-Rodriguez, R., Fierrez, J., Morales, A., & Ortega-Garcia, J. (2020). *Deepfakes and beyond: A survey of face manipulation and fake detection*. Information Fusion, 64, 131–148.
- Verdoliva, L. (2020). *Media forensics and deepfakes: An overview*. IEEE Journal of Selected Topics in Signal Processing, 14(5), 910–932.
- Zhang, K., Zhang, Z., Li, Z., & Qiao, Y. (2016). *Joint face detection and alignment using multitask cascaded convolutional networks*. IEEE Signal Processing Letters, 23(10), 1499–1503.